



Politechnika Krakowska
Wydział Informatyki i Telekomunikacji

Studia Niestacjonarne

Sprawozdanie z przedmiotu:

Uczenie Maszynowe w Diagnostyce Medycznej

Temat Projektu:

Klasyfikacja Obrazów Histopatologicznych

Wykonał:
Milosz Gronowski

1. Wstęp

Cel projektu:

Głównym celem projektu jest opracowanie modelu głębokiego uczenia, który byłby zdolny do automatycznej, wieloklasowej klasyfikacji obrazów histopatologicznych. System ma służyć jako narzędzie, które wspomagałoby decyzje medyczne. Zadaniem systemu jest przyspieszenie procesu segregacji próbek tkanek jelita grubego. Automatyzacja tego etapu pozwala na wstępne odfiltrowanie materiału i skupienie uwagi patomorfologa na przypadkach wymagających szczególnej analizy, co może skrócić czas postawienia ostatecznej diagnozy.

Opis danych:

W projekcie wykorzystano zbiór danych **PathMNIST**, który jest częścią benchmarku **MedMNIST v2**.

- **Charakterystyka** - Dane bazują na zbiorze NCT-CRC-HE-100K i zawierają skrawki tkanek barwione metodą hematoksyliny i eozyny (H&E).
- **Liczba przypadków** - Całkowita liczebność zbioru wynosi **107 180 obrazów**, które są podzielone na podzbiory w następujący sposób:
 - Zbiór treningowy - **89 996 obrazów (83,97%)**
 - Zbiór walidacyjny – **10 004 obrazów (9,33%)**
 - Zbiór testowy – **7 180 obrazów (6,70%)**
- **Typ danych** - Obrazy wieloklasowe (9 klas tkanek: Adipose, Background, Debris, Lymphocytes, Mucus, Smooth Muscle, Normal Colon Mucosa, Cancer-Associated Stroma, Colorectal Adenocarcinoma Epithelium).
- **Format** - Zbiór danych pozwala na eksperymentowanie z różnymi rozdzielczościami obrazów (28, 64, 128, 224 piksele) – w naszym projekcie skupiamy się wyłącznie na klasyfikacji modelu, którą przeprowadzimy na zbiorze obrazów o rozmiarze 64x64 piksele.
- **Balans klas** - Zbiór PathMNIST charakteryzuje się relatywnie dobrym zbalansowaniem klas. Każda z 9 klas stanowi około 10-11% całego zbioru danych. Dzięki temu można uchronić model przed naturalnym skrzywieniem w stronę dominującej klasy, co pozwala na ograniczenie stosowania zaawansowanych technik rekompensaty dysproporcji klasowych w większości przypadków. Drobne zachwianie występuje jedynie w zbiorze testowym dla kilku klas, gdzie rozkład wynosi 5-8%.
- **Jakość danych** - Obrazy pochodzą z referencyjnego źródła akademickiego (NCT-CRC-HE-100K) i zostały poddane profesjonalnej segmentacji oraz standaryzacji barwnej. Dane wejściowe pozbawione są artefaktów technicznych, uszkodzeń plików czy błędnych etykiet, co minimalizuje ryzyko błędów na etapie preprocessingu. Głównym wyzwaniem jakościowym jest kompresja rozdzielczości do formatu 64x64 piksele, co drastycznie redukuje szczegóły morfologiczne tkanki i nakłada na model konieczność ekstrakcji cech z mniej wyraźnych struktur.

Zakres projektu:

Realizacja projektu obejmuje pełną ścieżkę uczenia maszynowego (end-to-end pipeline):

- **Eksploracja danych (EDA)** – analiza statystyczna rozkładu klas oraz wizualizacja próbek w celu zrozumienia różnic morfologicznych między typami tkanek

- **Preprocessing** – normalizacja wartości pikseli, konwersja do tensorów oraz implementacja technik augmentacji danych (np. rotacje, odbicie) w celu zwiększenia zdolności generalizacyjnych modelu
- **Budowa i trenowanie modelu** – implementacja i porównanie różnych architektur sieci neuronowych.
- **Analiza i ewaluacja** – ocena modeli za pomocą metryk takich jak: Accuracy, AUC (Area Under Curve), Precision, Recall oraz analiza macierzy pomyłek (Confusion Matrix) w celu identyfikacji klas najtrudniejszych do rozróżnienia.

2. Środowisko programistyczne i konfiguracja projektu

Architektura technologiczna projektu:

W celu zapewnienia powtarzalności eksperymentów, optymalizacji obliczeniowej oraz stworzenia natywnego interfejsu graficznego, potok badawczy został oparty o następujące fundamenty technologiczne:

- **Język programowania** – Python w wersji 3.12. Wybór podyktowany natywnym wsparciem dla najnowszych wydań bibliotek uczenia głębokiego oraz znajomością języka.
- **Środowisko programistyczne** – Visual Studio Code.
- **Zarządzanie kodem źródłowym** – Repozytorium Git hostowane na platformie GitHub.

Biblioteki i zależności:

Środowisko uruchomieniowe zostało podzielone na logiczne warstwy odpowiedzialne za przetwarzanie danych, uczenie maszynowe, interpretowalność oraz interfejs użytkownika. Poniższa tabela przedstawia szczegółową charakterystykę wykorzystanych pakietów.

Głębokie uczenie (Deep Learning):

- **torch** – Główny silnik obliczeniowy implementacja sieci.
- **torchvision** – Operacje na danych obrazowych, transformacje augmentacyjne i ekstrakcja gradientów do algorytmu Grad-CAM.

Przetwarzanie obrazów i matematyka:

- **numpy** – Szybkie operacje macierzowe na strukturach pikseli, obsługa tablic wielowymiarowych.
- **Pillow (PIL)** – Podstawowe ładowanie, konwersja i bezpieczna manipulacja plikami graficznymi.
- **opencv-python** – Konwersja przestrzeni barwnych RGB, generowanie i nakładanie map ciepła CAM.

Ewaluacja i statystyka:

- **scikit-learn** – Wyznaczanie macierzy pomyłek, metryk oraz podziału danych.
- **scipy** – Obliczenia statystyczne, optymalizacja matematyczna progów decyzyjnych.

Optymalizacja i interpretowalność:

- **optuna** – Automatyczne przeszukiwanie przestrzeni hiperparametrów.
- **shap** – Wyznaczanie wartości Shapleya dla warstw splotowych w celu interpretacji decyzji sieci.

Interfejs użytkownika (GUI):

- **PyQt6** – Architektura interfejsu CADx, obsługa zdarzeń, wątków i widżetów.

Optymalizacja i narzędzia:

- **tqdm** – Wizualizacja pasków postępu w czasie rzeczywistym podczas uczenia i walidacji.
- **matplotlib** – Generowanie wykresów.
- **seaborn** – Wizualizacja macierzy pomyłek.

Instrukcja instalacji i replikacji środowiska:

Klonowanie repozytorium projektu:

```
git clone https://github.com/[NAZWA_UŻYTKOWNIKA]/pathMNIST.git
cd pathMNIST
```

Instalacja dedykowanych zależności:

```
pip install -r requirements.txt
```

3. Przygotowanie danych

Eksploracyjna analiza danych (EDA):

BALANS KLAS

W celu weryfikacji struktury zbioru danych oraz uniku założeń czysto teoretycznych, przeprowadzono analizę rozkładu klas dla badanych obrazów o rozdzielczości 64x64 piksele. Całkowity zbiór 107180 przypadków został przeanalizowany z rozbiciem na trzy podzbiory: treningowy, walidacyjny oraz testowy.

Tabela prezentująca szczegółowy rozkład liczebności oraz udziału procentowego poszczególnych klas:


ID KLASY	NAZWA KLASY TKANKOWEJ	ZBIÓR TRENINGOWY (TRAIN)	ZBIÓR WALIDACYJNY (VAL)	ZBIÓR TESTOWY (TEST)
0	Adipose (Tkanka tłuszczowa)	9 366 (10.41%)	1 041 (10.41%)	1 338 (18.64%)
1	Background (Tło)	9 509 (10.57%)	1 057 (10.57%)	847 (11.80%)
2	Debris (Zanieczyszczenia komórkowe)	10 360 (11.51%)	1 152 (11.52%)	339 (4.72%)
3	Lymphocytes (Limfocyty)	10 401 (11.56%)	1 156 (11.56%)	634 (8.83%)
4	Mucus (Śluz)	8 006 (8.90%)	890 (8.90%)	1 035 (14.42%)
5	Smooth Muscle (Mięśnie gładkie)	12 182 (13.54%)	1 354 (13.53%)	592 (8.25%)
6	Normal Colon Mucosa (Zdrowa śluzówka)	7 886 (8.76%)	877 (8.77%)	741 (10.32%)
7	Cancer- Associated Stroma (Zrąb nowotworowy)	9 401 (10.45%)	1 045 (10.45%)	421 (5.86%)

8	Colorectal Adenocarcinoma Epithelium (Rak)	12 885 (14.32%)	1 432 (14.31%)	1 233 (17.17%)
SUMA	Wszystkie przypadki	89 996 (100%)	10 004 (100%)	7 180 (100%)

Wnioski z analizy dystrybucji klas:

- **Zbiór uczący i walidacyjny** – Rozkład wszystkich 9 klas wykazuje bardzo wysoką spójność logiczną. Proporcje klas w obu podzbiorach są niemal identyczne. Udowadnia to poprawność zastosowanego przez twórców zbioru benchmarku podziału warstwowego. Maksymalna zachodząca dysproporcja pomiędzy poszczególnymi klasami wynosi około 1.6 : 1 (dominująca klasa 8 – około 14.32% i 14.31% oraz mniejszościowa klasa 6 – około 8.76% i 8.77%). Dane są więc relatywnie dobrze zbalansowane, co ogranicza konieczność stosowania technik oversamplingu, czy też modyfikacji zbiorów na etapie uczenia bazowego.
- **Zbiór testowy** – Weryfikacja ujawniła odmienny rozkład dla zbioru testowego. Udział niektórych klas drastycznie wzrasta (np. klasa 0 – 18.64%), a niektórych klas znacznie spada (np. klasa 2 – 4.72%). Taka rozbieżność może doprowadzić do istotnych wyzwań w ocenie modeli, gdyż klasyczne metryki, takie jak np. Accuracy, mogą być przez to naciągane przez klasy dominujące w teście. Wymusza to oparcie ostatecznej oceny systemu na niezależnych miarach od liczebności, głównie Macro F1-Score, a także sprawdzenia wyników klasyfikacji dla poszczególnych klas, zwłaszcza tych, które miały mniejszą reprezentację w zbiorze testowym.

WIZUALNA OCENA PRÓBEK I ZRÓZNIOCOWANIA MORFOLOGICZNEGO



W pierwszym kroku analizy jakościowej wygenerowano zestawienie losowych mikro-fotografii dla każdej z 9 klas, co przedstawia powyższy rysunek. Na jego podstawie zaobserwowano cechy charakterystyczne dla wyróżniających się klas:


- **Adipose (ADI)** – Klasa ta prezentuje puste, białe przestrzenie o ostro zarysowanych, wielokątnych granicach. Są to pęcherzyki lipidowe, które naturalnie nie absorbują barwników

histologicznych. Przykłady obrazów dla tej klasy znacznie odbiegają na pierwszy rzut oka od reszty klas, co może sugerować łatwiejszą jej klasyfikację w projekcie.

- **Background (BACK)** – Pokazuje strukturę jednolitego tła cyfrowego o delikatnym zaszumieniu lub pojedynczych rozproszonych artefaktach.
- **Lymphocytes (LYM) oraz Collorectal Adenocarcinoma Epithelium (TUM)** – Obie te klasy charakteryzują się bardzo wysoką gęstością upakowania ciemnych, fioletowo-granatowych struktur. Wynika to z faktu, że nacieki zapalne (limfocyty) oraz komórki nowotworowe posiadają przerośnięte, patologiczne jądra komórkowe, które intensywnie pochłaniają hematoksylinę.
- **Mucus (MUC) oraz Smooth Muscle (MUS)** – Śluz (MUC) wykazuje strukturę włóknistą, rozmytą i jasnoróżową, natomiast mięśnie gładkie (MUS) charakteryzuje się podłużnym, uporządkowanym, pasmowym układem komórek o intensywnym zabarwieniu eozyną (kolor różowo-czerwony).

Wnioski – Istnieje wyraźna, wzrokowa separowalność tekstur, gęstości komórkowej oraz geometrii struktur. Filtry splotowe (zwłaszcza w głębszych warstwach sieci) będą miały stabilne podstawy do ekstrakcji unikalnych cech przestrzennych, takich jak chociażby krawędzie pęcherzyków czy kierunek włókien mięśniowych.


ANALIZA ROZKŁADU INTENSYWNOŚCI PIKSELI W KANAŁACH RGB



Przeanalizowano gęstość rozkładu intensywności pikseli na próbie 5000 losowych próbek zdjęć z bazy. Zaobserwowano silny rozkład bimodalny (dwugarbny) we wszystkich trzech kanałach. Pozwoliło to wyciągnąć następujące wnioski:

- Ostry, wysoki szczyt w przedziale około 200-240 pikseli dla kanałów czerwonego (R) oraz niebieskiego (B) potwierdza obecność jasnego, bliskiego bieli tła cyfrowego, które dominuje na większości zdjęć. Szerokie wzniesienie w granicach około 100-180 pikseli odzwierciedla właściwy kolor tkanki. Nałożenie na wykresie czerwonego i niebieskiego koloru sugeruje charakterystyczny purpurowo-fioletowy odcień typowy dla barwienia metodą H&E.
- Przewaga bardzo jasnego tła niesie ryzyko, że model w pierwszych epokach skupi się na tle zamiast na strukturze komórek. Wymusza to zastosowanie standaryzacji (Z-score) w preprocessingu, w celu wycentrowania wartości wokół zera i umożliwieniu równorzędnej nauki cech zarówno z jasnych, jak i ciemnych obszarów tkanki

ANALIZA JASNOŚCI KLAS TKANKOWYCH (BOX-PLOT)




Wykres pudełkowy (box-plot) przedstawia średnią jasność obrazów (po konwersji do skali szarości) w podziale na 9 klas tkankowych. Wyniki pozwoliły na sformułowanie poniższych wniosków:

- Klasa Adipose (ADI) jest zdecydowanie najjaśniejsza, uzyskując jako jedyna medianę powyżej 175 pikseli w skali szarości, uzyskując wynik ponad 200 pikseli na medianie. Pudełko tej klasy jest wąskie, co świadczy o niskiej wariancji.
- Klasa Background (BACK) wyróżnia się ekstremalnie szerokim rozstępem, praktycznie na całą skalę szarości i zdecydowanie najszerzym pudełkiem, co odzwierciedla zróżnicowaną jasność kadrów referencyjnych tła.
- Klasy o gęstym utkaniu komórkowym, takie jak Lymphocytes (LYM) oraz Colorectal Adenocarcinoma Epithelium (TUM), są ciemniejsze uzyskując wynik mediany poniżej 150 pikseli w skali szarości.
- Pozostałe klasy posiadają także wąskie pudełka, co również świadczy o ich niskiej wariancji w skali szarości, jednak mieszczą się one na podobnym poziomie około 150-175 pikseli.

Pudełka klas jasnych lub ciemniejszych w wielu przypadkach na siebie w ogóle nie nachodzą. Oznacza to, że sieć neuronowa już w swoich początkowych warstwach spłotowych będzie w stanie z dużą łatwością rozróżnić tkanki na samej dystrybucji luminacji.

ANALIZA RZUTOWANIA PRZESTRZENI CECH (REDUKCJA WYMIAROWOŚCI PCA)



Wykres punktowy przedstawia rzutowanie spłaszczonych obrazów do przestrzeni dwuwymiarowej przy użyciu algorytmu PCA. Został wygenerowany na bazie 3000 losowych próbek w celu utrzymania przejrzystości wykresu. Pozwolił na sformułowanie następujących wniosków:

- Na wykresie widoczne jest duże wymieszanie punktów w centrum układu współrzędnych. Kluczowe klasy nakładają się na siebie. Wyjątek stanowią klasa Adipose (ADI) w kolorze czerwonym po prawej stronie oraz klasa Background (BACK), która jest odizolowana po lewej stronie od największego skupiska, co pokrywa się z ich unikalną charakterystyką ukazaną na wykresie pudełkowym
- Całkowity brak liniowej separacji dla większości klas to bezpośredni dowód na to, że proste modele liniowe poniosły by porażkę w tym zadaniu, a dla poprawnej klasyfikacji tak skomplikowanych i wymieszanych struktur histopatologicznych, niezbędne jest zastosowanie nieliniowych modeli uczenia głębokiego (sieci CNN).

Przetwarzanie danych:

W ramach potoku przygotowania danych zaimplementowano standaryzowany zestaw technik inżynierii danych wejściowych, których celem jest optymalizacja procesu wyznaczania wag oraz zapewnienie stabilności numerycznej podczas wstecznej propagacji błędów.

KONTROLA BRAKÓW DANYCH (IMPUTACJA)

W zbiorze danych nie zastosowano żadnych algorytmów imputacyjnych (uzupełnienia braków) ze względu na kompletność zbioru w 100%, co sprawdzono po załadowaniu pliku archiwum. Funkcja sprawdzająca potwierdziła brak wartości NaN we wszystkich podzbiorach. Ponadto specyfika struktur obrazów cyfrowych, zdefiniowana jako ciągłe czterowymiarowe macierze NumPy o stałym kształcie (89996x64x64x3) uniemożliwia pominięcie pojedynczych wartości pikseli bez wywołania błędów alokacji pamięci.

NORMALIZACJA ZAKRESU (MIN-MAX)

Surowe matryce zapisane w formacie całkowitoliczbowym (0-255) są konwertowane do zmiennoprzecinkowych tensorów *PyTorch*. Zgodnie z oficjalną dokumentacją biblioteki *torchvision*, wywołanie metody *transforms.ToTensor()* automatycznie wykrywa wejściowy format danych

`numpy.uint8` reprezentujący piksele i wykonuje operację mapowania liniowego, dzieląc każdą wartość przez 255. W efekcie dane zostają przeskalowane do przedziału $[0,1]$. Chroni to się przed dominacją zmiennych o dużych wartościach matematycznych na starcie uczenia.

STANDARYZACJA BARWNA (ODPOWIEDNIK Z-SCORE)

Zastosowano operację standaryzacji kanałów RGB, która centruje rozkłady wokół zera matematycznego z odchyleniem standardowym równym 1, co bezpośrednio neutralizuje dominację jasnego tła wykazaną na wykresie gęstości KDE. Odbywa się to z wykorzystaniem funkcji `transforms.Normalize()`.

REDUKCJA WYMIAROWOŚCI I BADANIE SEPAROWALNOŚCI

Przed przystąpieniem do modelowania zbadano stopień skomplikowania przestrzeni cech poprzez redukcję wymiarowości za pomocą algorytmu PCA. Operacja ta została zaimplementowana za pomocą spłaszczenia obrazów z formatu trójwymiarowego do jednego wektora oraz wywołania biblioteki `scikit-learn`. Wyniki tego przetwarzania dostarczyły podstaw do odrzucenia modeli liniowych na rzecz głębokich sieci spłotowych.

INŻYNIERIA LOSOWOŚCI

Eksperymenty głębokiego uczenia charakteryzują się naturalną stochastycznością. Aby zapewnić powtarzalność wyników, wdrożono procedurę blokowania ziaren losowości. Zdefiniowana jest stała `GLOBAL_SEED = 42` w pliku `config.py`. Gwarantuje to identyczny przebieg uczenia sieci przy uruchamianiu, gdyż zmienna jest importowana do pozostałych plików.

4. Modelowanie i ewaluacja

Wybór modeli:

Bezpośrednim punktem wyjścia do sformułowania oraz zróżnicowania puli testowych algorytmów klasyfikacji były wnioski wyciągnięte na etapie eksploracyjnej analizy danych (EDA). Przeprowadzone tam rzutowanie przestrzeni cech wysokowymiarowych przy użyciu algorytmu PCA ujawniło całkowity brak liniowej separowalności poszczególnych podklas oraz ich silne wymieszanie w centrum układu. Stanowiło to podstawę do odrzucenia prostych, klasycznych struktur na rzecz zaawansowanych i nieliniowych modeli uczenia głębokiego (Deep Learning), które charakteryzują się wyższą pojemnością hipotez matematycznych.

W celu realizacji rzetelnego i szerokiego przeglądu możliwych klasyfikatorów, w pierwszej fazie badawczej zaimplementowano 6 różnych modeli, które utworzono w module `Models.py`:

1. **Regresja Logistyczna** (ML Baseline) – Prostszy klasyfikator liniowy przetwarzający surowy, spłaszczony wektor pikseli o wymiarze 1288 cech. Model ten nie posiada zdolności ekstrakcji kontekstu przestrzennego. Wdrożony w celu udowodnienia postawionej tezy przy analizie PCA o niewydolności metod liniowych w konfrontacji ze złożonymi strukturami medycznymi.
2. **SimpleCNN** (DL Baseline) – Autorska, trójwarstwowa sieć spłotowa uzupełniona o warstwę normalizacji wsadowej oraz warstwę redukcji wymiarów przestrzennych. Model ten jest uczony całkowicie od podstaw, co pozwala ocenić wyjściowy potencjał ekstrakcji cech morfologicznych tkanek i geometrii struktur (takich jak pęcherzyki lipidowe w klasie *Adipose* czy kierunek pasm w klasie *Smooth Muscle*) bez wsparcia zewnętrznymi zasobami wiedzy.
3. **ResNet18** (Transfer Learning – Architektura Bazowa) – Klasyczna sieć spłotowa wykorzystująca rezydualne połączenia spłotowe. Zastosowano wariant z wagami zainicjalizowanymi na zbiorze *ImageNet*. Obecność połączeń skrótowych skutecznie przeciwdziała zjawisku

degradacji i zanikania gradientu, co pozwala na stabilne przeniesienie wiedzy o uniwersalnych krawędziach i przejściach tonalnych na specyficzny, bimodalny rozkład barwienia histologicznego hematoksyliną i eozyną (H&E).

4. **ResNet50** (Transfer Learning – Architektura Głęboka) – Rozbudowana, 50-warstwowa wersja sieci rezydualnej, oparta na blokach typu *Bottleneck*. Implementacja tego modelu ma na celu weryfikację kryterium skali – sprawdzenie, czy drastyczne zwiększenie liczby parametrów numerycznych i głębokości sieci splotowej przyniesie istotny statystycznie przyrost celności diagnostycznej przy relatywnie małej rozdzielczości obrazu wejściowego (64x64 piksele).
5. **MobileNetV3-Large** (Architektura zorientowana na efektywność) - Nowoczesna, lekka sieć neuronowa zaprojektowana do optymalizacji zasobów obliczeniowych. Opiera się na technologii spłotów rozdzielnych głębokościowo oraz wbudowanych blokach globalnego kontekstu *Squeeze-and-Excitation*. Model ten wprowadzono w celu zbadania kompromisu inżynierskiego pomiędzy kosztem sprzętowym (czas treningu, zużycie VRAM) a jakością predykcji wieloklasowej.
6. **DenseNet121** (Zaawansowana architektura medyczna) – Architektura reprezentująca paradygmat gęstych połączeń rezydualnych. W przeciwieństwie do tradycyjnych sieci, każda warstwa w bloku gęstym przyjmuje jako stany wejściowe mapy cech ze wszystkich poprzednich warstw i przekazuje własne mapy do następnych warstw. Maksymalizuje to ponowne wykorzystanie cech i eliminuje problem zanikania gradientów.

Proces trenowania:

Ważnym etapem projektowania systemu głębokiego uczenia jest zdefiniowanie środowiska eksperymentalnego, które zapewni obiektywizm porównawczy oraz wykluczy zjawisko wycieku danych. Proces trenowania wstępnego każdego z 6 modeli odbył się w ujednolicony i zorganizowany sposób:

- **Podział danych** – Eksperyment zrealizowano z wykorzystaniem oficjalnego podziału blokowego, dostarczonego w danych PathMNIST. Całkowite dane podzielone zostały pomiędzy trzy odizolowane podzbiory – zbiór treningowy (ok. 84% danych, 89996 obrazów), zbiór walidacyjny (ok. 9% danych, 10004 obrazy) oraz zbiór testowy (ok. 7% danych, 7180 obrazów).
- **Metoda walidacji** – Zrezygnowano świadomie w projekcie z implementacji klasycznej walidacji krzyżowej. K-krotny podział wiązałby się z dużym kosztem obliczeniowym przy tak dużej bazie obrazów w zbiorach danych.
- **Strategie samplingu i balans klas** - Jak wykazano w sekcji analizy eksploracyjnej (EDA), rozkład wszystkich klas w podzbiorze uczącym oraz walidacyjnym cechuje się naturalną równowagą. Z tego względu odrzucono techniki sztucznego tworzenia próbek (np. oversampling). Dodatkowo takie czynności mogłyby zniekształcić struktury w plikach obrazowych.
- **Wstępne trenowanie modeli** – W pierwszej fazie trenowania modeli wzięło udział 6 modeli, w celu wyłonienia modelu do dalszych, bardziej zaawansowanych prac optymalizacyjnych. Wszystkie modele uruchomiono na identycznych bazowych hiperparametrach:
 - Rozmiar paczki danych (batch size) – 128
 - Algorytm optymalizujący – Adam
 - Współczynnik uczenia (learning rate) – 0.001
 - Funkcja błędu – CrossEntropyLoss
 - Liczba epok – 5

Metryki trenowania modeli:

W celu zapewnienia pełnej przejrzystości procesu trenowania modeli, każda z 6 badanych architektur była monitorowana i rejestrowana w ten sam sposób. Dla każdego modelu przeprowadzono pełny cykl treningowy złożony z 5 epok. Na koniec każdej epoki system dokonywał natychmiastowej ewaluacji numerycznej (zbiór walidacyjny mierzony za każdym razem od nowa, aby nie występował on jako zbiór na którym model trenuje), wyznaczając zestaw czterech wskaźników, który badał poprawność klasyfikacji dla danego modelu i służył jako detektor do zjawiska przeuczenia:


- Strata treningowa (Train Loss)
- Celność treningowa (Train Accuracy)
- Strata Walidacyjna (Val Loss)
- Celność Walidacyjna (Val Accuracy)

W celu przekształcenia danych numerycznych w czytelną formę analizy, która posłuży nam do wybrania najlepszego modelu, który będzie w dalszej części optymalizowany sporządzono zestaw wykresów:

- Indywidualne wykresy dla poszczególnych modeli dla każdej architektury:
 - **Wykres celności** (Accuracy Curve) – Dynamika celności klasyfikacji po kolejnych epokach
 - **Wykres funkcji straty** (Loss Curve) – Ocena zbieżności parametrów sieci i identyfikacja momentu przeuczenia
- Zbiorcze wykresy w celu porównania modeli oraz selekcji optymalnego modelu:
 - **Zbiorczy wykres trajektorii walidacyjnej** (Validation Accuracy Comparison) – Wykres liniowy przedstawiający przebieg Val Accuracy po epokach dla każdego modelu
 - **Efektywność końcowa** (Final Performance Ranking) – Wykres kolumnowy reprezentujący ostateczną, najwyższą celność modeli

Wyniki trenowania modeli:


LOGISTIC REGRESSION



Wyniki dla modelu LogisticRegression (Regresja Logistyczna) idealnie odzwierciedliły hipotezę, która została sformułowana na etapie analizy PCA. Pokazała bezradność modelu liniowego w starciu ze skomplikowaną strukturą obrazu medycznego. Wnioski na podstawie wyników tego modelu:

- **Niska zdolność generalizacji i pułap niedouczenia** – Maksymalna celność walidacyjna osiągnięta przez model w 4 epoki wynosiła zaledwie 32,63%, a celność treningowa ustabilizowała się także na skrajnie niskim poziomie ok. 35%. W przypadku problemu klasyfikacji 9-klasowego, wynik uzyskany przez prosty model jakim jest regresja logistyczna należy uznać za bardzo mały. Model liniowy nie był w stanie wyznaczyć stabilnych granic decyzyjnych w przestrzeni pikselowej.
- **Potwierdzenie założeń w analizie PCA** – Zatrzymanie celności na niskim pułapie oraz rozjazd krzywych w ostatniej epoce stanowi bezpośredni, empiryczny dowód słuszności hipotezy sformułowanej na etapie analizy eksploracyjnej (EDA). Wynik tego modelu uzasadnia konieczność korzystania z głębokich architektur splotowych w kolejnych krokach eksperymentu.


SIMPLE CNN



Wyniki dla modelu SimpleCNN (Autorska sieć splotowa) wykazały znaczny zysk jakości w porównaniu do modelu liniowego. Nawet prosta struktura konwolucyjna bardzo dobrze radzi sobie z ekstrakcją nieliniowych cech przestrzennych z obrazów tkankowych. Wnioski:

- **Dobry wynik i wysoka zdolność generalizacji** – Model z epoki na epokę poprawiał swoje wyniki, osiągając w ostatniej epoce bardzo dobrą celność walidacyjną na poziomie 92,49%. Ukazanie, że krzywa walidacyjna podąża blisko za krzywą treningową świadczy o tym, że autorskie warstwy splotowe połączone z Dropoutem, skutecznie wyciągnęły uniwersalne cechy struktur medycznych bez wpadania w głębokie przeuczenie.
- **Stabilizacja funkcji** – Po początkowych wahaniach w 2 epoki, wynik modelu się ustabilizował. Optymalizator *Adam* sprawnie skorygował stan już w 3 epoki, a funkcja błędu dla obu podzbiorów gładko opadała w kolejnych epokach.


RESNET18



Wyniki dla modelu ResNet18 ukazały szybki start, ale także trudności adaptacyjne w późniejszych epokach przy domyślnych hiperparametrach. Wnioski na podstawie wyników tego modelu:

- **Szybka zbieżność startowa** – Model już w 1 epoce osiągnął bardzo wysoką celność walidacyjną na poziomie 94,15%. Gotowe wagi pre-trenowane na zbiorze ImageNet skutecznie i natychmiastowo zaadaptowały się do rozpoznania podstawowych struktur i krawędzi mikrofotografii medycznych.
- **Silne przeuczenie** – Od 3 epoki krzywe treningowa i walidacyjna zaczęły się rozjeżdżać, co świadczy o przeuczeniu modelu. Celność walidacyjnie malała, podczas gdy celność treningowa gwałtownie rosła w kolejnych epokach. Domyślny współczynnik uczenia (0,001) był zbyt agresywny dla tej sieci, przez co model dopasował się do zbioru treningowego.

RESNET50




Wyniki dla modelu ResNet50 przyniosły wyższe wskaźniki skuteczności niż wersja ResNet18, jednak przebieg optymalizacji był niestabilny. Wnioski na podstawie wyników tego modelu:

- **Wyższa celność maksymalna** – Model osiągnął bardzo wysoki wynik punktowy celności walidacyjnej w 2 epoce na poziomie 97,66%. Porównując to do wersji ResNet18, można sformułować wniosek, że większa pojemność matematyczna 50-warstwowej sieci oraz zaawansowane bloki filtrujące lepiej dopasowują się do trudnych struktur histopatologicznych.
- **Duża niestabilność procesu uczenia** – Po znakomitym wyniku w 2 epoce, wynik spadł gwałtownie w epoce 3 do poziomu 94,07%. Pomimo odzyskania wyników w 5 epoce, duże spadki krzywej świadczą o tym, że głęboka struktura sieci ma tendencję do gubienia

optymalnych minimów lokalnych przy braku precyzyjnie dobranego harmonogramu tłumienia współczynników uczenia.


MOBILE NET V3



Wyniki dla modelu przyniosły fantastyczny wynik końcowy, wykazując dynamiczny, ale momentami gwałtowny przebieg procesu optymalizacji. Wnioski:

- **Znakomity wynik końcowy i wysoka efektywność filtrów** – Model zakończył fazę screeningu z najwyższym wynikiem celności walidacyjnej na poziomie 98,76% i to w ostatniej epoce. Pokazuje to, że mechanizmy splotów rozdzielnych połączone z modułami uwagi *Squeeze-and-Extraction* idealnie wyłapują kluczowe wzorce histopatologiczne, oferując precyzję przy zachowaniu niższego kosztu obliczeniowego.
- **Gwałtowne załamanie i powrót do stabilności** – Widoczna na wykresach jest anomalia w postaci wyniku z 4 epoki, gdzie celność walidacyjnie drastycznie spadła, a funkcja straty walidacyjnej znaczenie wzrosła. Zjawisko to, najprawdopodobniej spowodowane było chwilowym wypadnięciem optymalizatora z lokalnego minimum. Zostało jednak skorygowane w 5 epoce, co świadczy o elastyczności i stabilności powrotu architektury.

DENSENET121




Wyniki dla modelu DenseNet121 pokazały ogromny potencjał diagnostyczny, charakteryzując się dosyć płynnym i stabilnym tokiem uczenia po początkowej, chwilowej destabilizacji. Wnioski na podstawie wyników tego modelu:

- **Wysoka stabilność końcowa i zbieżność** – Po załamaniu w 2 epoce, wykres w kolejnych epokach prezentuje stabilny przebieg. Mechanizm ponownego wykorzystania cech zapobiegł przeuczeniu i pozwolił sieci na płynne zabezpieczenie stabilnego minimum lokalnego.

- **Wczesna anomalia i samokorekta** – Na wykresie widoczna jest anomalia w 2 epoce. Podobnie jak w przypadku MobileNetV3, architektura ta wykazała się jednak natychmiastową zdolnością do adaptacji niwelując tą anomalię

ZBIORCZE WYNIKI



Zbiorcze zestawienie wszystkich modeli pozwoliło na ich porównanie i wskazanie modelu, który będzie wykorzystywany w fazie optymalizacji i posłuży do klasyfikacji w naszym projekcie. Wnioski:

- **Zdecydowana przewaga Transfer Learningu nad modelami bazowymi** – Wszystkie zaawansowane sieci splotowe pre-trenowane na zbiorze ImageNet (MobileNetV3, DenseNet121, ResNet50, ResNet18) bezbłędnie poradziły sobie z nieliniowością danych PathMNIST, przekraczając barierę 94% celności walidacyjnej. Wyniki te deklasują bazowy model SimpleCNN (92,49%) oraz skrajnie niedouczoną regresję logistyczną (32,63%), udowadniając kluczową rolę głębokich filtrów konwolucyjnych w ekstrakcji detali histopatologicznych.

- **Wybór architektury do dalszej fazy projektu** – Ze względu na wysoki wynik celności walidacyjnej na poziomie 98,76% wybrany został do dalszej części projektu model MobileNetV3. Architektura ta wykazała się nie tylko rewelacyjną zdolnością generalizacji, ale i doskonałą dynamiką samokorekty po załamaniu w epoce 4. Tuż za nią uplasował się model DenseNet121 (97,85%), który zaprezentował najbardziej stabilną i płaską trajektorię wzrostu. Mając na uwadze najwyższy uzyskany surowy wskaźnik celności, to właśnie architektura MobileNetV3 została zakwalifikowana jako jedyny reprezentant do Fazy 2 projektu, w której zostanie poddana zaawansowanej optymalizacji hiperparametrów przy użyciu frameworku Optuna.

Dobór hiperparametrów:

W celu zmaksymalizowania zdolności generalizacyjnych wybranej architektury MobileNetV3 oraz eliminacji niestabilności numerycznych zaobserwowanych w fazie przeglądowej, zrezygnowano z tradycyjnych metod przeszukiwania przestrzeni parametrów na rzecz zaawansowanych algorytmów probabilistycznych.

Zamiast metod deterministycznych, takich jak przeszukiwanie po siatce (Grid Search – podejście nieoptymalne obliczeniowo, podatne na pomijanie minimów lokalnych) czy przeszukiwanie losowe (Random Search – brak ciągłości wnioskowania pomiędzy iteracjami), zastosowano Optymalizację Bajesowską (Bayesian Optimization) zaimplementowaną w środowisku Optuna.

Proces ten opiera się na estymatorze TPE (Tree-structured Parzen Estimator). Działa on w pętli sprzężenia zwrotnego: każda kolejna próba (*trial*) nie jest losowa, lecz dobierana na podstawie probabilistycznego modelu historii poprzednich wyników. Algorytm maksymalizuje tzw. funkcję poprawy (Expected Improvement), kierując zasoby obliczeniowe wyłącznie w obszary przestrzeni hiperparametrów, które statystycznie obiecują najwyższy wzrost celności walidacyjnej (*Val Accuracy*).

Optymalizację bajesowską uruchomiono dla 10 niezależnych prób, gdzie każda próba inicjalizowała kompletnie nowy, czysty model MobileNetV3 z wagami ImageNet, zapobiegając błędowi metodologicznemu przenoszenia wiedzy między konfiguracjami. Przestrzeń poszukiwań zdefiniowano następująco:

- **Współczynnik uczenia** (Learning rate) – Zakres ciągły w przedziale od 0,00001 do 0,001. Szukano wartości mniejszej niż domyślne 0,001, aby ustabilizować trajektorię gradientu.
- **Algorytm optymalizujący** (Optimizer) – Wybór kategoriyczny spośród trzech zróżnicowanych podejść numerycznych: *Adam* (adaptacyjny model), *RMSprop* (skalowanie gradientu średnią kroczącą) oraz *SGD* (pęd momentum 0,9).
- **Rozmiar paczki** (batch_size) – Wybór dyskretny pomiędzy 64 a 128.

W celu optymalizacji czasu procesu wdrożono mechanizm wczesnego kończenia słabych eksperymentów – MedianPruner. Po zakończeniu pierwszej epoki w danej próbie, uzyskana celność walidacyjna była komparowana z medianą dotychczasowych wyników na tym samym etapie. Jeśli próba rokowała gorzej niż dotychczasowe ramie statystyczne, była natychmiastowo degradowana i przerywana, co pozwoliło na zaoszczędzenie czasu w fazie optymalizacji modelu.

WYNIKI

Przebieg 10 prób optymalizacyjnych wykazał wysoką dynamikę. Algorytm bajesowski bezbłędnie zidentyfikował rejony niestabilne – próby oparte na algorytmie *SGD* oraz próby z agresywnym

crokiem uczenia ($learning_rate > 0.0005$) były natychmiast odrzucane przez system pruningu ze względu na niską zbieżność startową.


Najwyższą wydajność oraz optymalny, gładki profil numeryczny osiągnięto w próbie nr 4, która wskazała zestaw hiperparametrów do dalszej części projektu:

- **Learning_rate:** 0,000158 (Wartość niemal 6-krotnie niższa niż domyślna, zapewnia precyzyjne kroki w dół funkcji kosztu i zapobiega fluktuacjom)
- **Optimizer:** Adam (Adaptacyjny optymalizator najlepiej radzi sobie z nieliniową topologią PathMNIST)
- **Batch_size:** 64 (Mniejszy rozmiar paczki wprowadza kontrolowany szum, ułatwiający modelowi ucieczkę z ostrych minimów lokalnych)

Finalny proces trenowania:

Dla finalnie wybranego modelu (**MobileNetV3**) zasilanego zoptymalizowanymi parametrami wyznaczonymi w procesie optymalizacji bayesowskiej, przeprowadzono pełnowymiarowy ostateczny trening. Proces uczenia został zaprogramowany na maksymalnie 15 epok, przy jednoczesnym zabezpieczeniu pętli algorytmem wczesnego zatrzymania (*Early Stopping*), które zostało zdefiniowane na zatrzymanie procesu nauczania i powrót do epoki z najlepszym wynikiem przy braku poprawy wskaźnika celności walidacyjnej (*Val Accuracy*) przez 3 epoki (*patience = 3*). Potok treningowy został zaprojektowany w modularny sposób, separując fazę trenowania i walidacji wyników. Moduł treningowy zwracał końcowy model oraz historię treningu po kolejnych epokach.

FUNKCJA CELNOŚCI (ACCURACY CURVE)




Główny wskaźnik skuteczności modelu wykazuje stabilną, logarytmiczną trajektorię wzrostu pozbawioną gwałtownych anomalii, które były widoczne w fazie wczesnego trenowania modelu przy jego selekcji. Przebieg procesu nauczania:

- **Inicjalizacja** (Epoka 1) – Model wystartował z poziomu 92,11% celności treningowej oraz aż 97,06% celności walidacyjnej. Tak wysoka skuteczność startowa na zbiorze walidacyjnym wynika z efektywnego wykorzystania mechanizmu Transfer Learningu (wstępne wagi *ImageNet*) skorelowanego z natychmiastowym dopasowaniem globalnych filtrów splotowych do struktur histopatologicznych.

- **Stabilizacja** (Epoki 2-10) – Wykres przechodzi w stabilną fazę. Model płynnie domyka proces optymalizacji, dopasowując wagi dla najtrudniejszych morfologicznie próbek. Lekkie wahania na zbiorze walidacyjnym zostały natychmiast skorygowane przez optymalizator w kolejnych epokach.
- **Punkt krytyczny** (Epoka 11) – Model osiąga swoje maksimum, wykazując rekordową celność walidacyjną na poziomie 99,28%, przy celności treningowej wynoszącej 99,62%. Bardzo mała różnica pomiędzy obiema krzywymi świadczy o świetnym dopasowaniu modelu do specyfiki zbioru PathMNIST.
- **Interwencja Early Stopping** (Epoki 12-14) – Wskaźnik walidacji nie generuje już lepszych wyników, co prowadzi do wcześniejszego zatrzymania procesu nauczania i cofnięcia się do stanu z epoki 11.

FUNKCJA STRATY (LOSS CURVE)



Wykres funkcji nauczania potwierdza poprawność wykonanego eksperymentu:

- W epoce 2 jest zauważalny, przejściowy i gwałtowny skok straty walidacyjnej do poziomu 0,2406, któremu nie towarzyszył spadek celności. Świadczy to o klasycznym przypadku numerycznego „przestrzelenia” (*ang. overshooting*) gradientu w nieliniowej topografii funkcji kosztu. Dzięki dobrze dobranemu parametrowi *learning_rate* na poziomie 0,000158, optymalizator natychmiast wytłumił te oscylacje.
- W końcowej epoce 11, która uzyskała najlepszy wynik, funkcja straty wynosi niski poziom 0,0288. Tak niska wartość błędu przy 9-klasowym zbiorze oznacza, że model przypisuje klasom bardzo wysoki wynik prawdopodobieństwa w wielu przypadkach.

PODSUMOWANIE

Podsumowując, uzyskane krzywe zbieżności udowodniły, że proces optymalizacji bayesowskiej w pełni zrealizował swoje zadanie inżynierskie. Architektura *MobileNetV3* została wyszkolona w sposób stabilny, powtarzalny i bezpieczny pod kątem medycznym, osiągając maksymalną zdolność generalizacji bez wejścia w fazę szkodliwego przeuczenia. Końcowa celność walidacyjna modelu nie tylko została całkowicie uodporniona na anomalie numeryczne, ale jej maksymalny poziom wzrósł z niestabilnego punktu **98,76%** (odnotowanego w fazie selekcji modelu) do rekordowego, w pełni zbieżnego poziomu **99,28%**.

Finalna ewaluacja:

Ostateczny test efektywności zoptymalizowanej architektury MobileNetV3 przeprowadzono na ukrytym dotąd zbiorze testowym, składającym się z 7180 próbek histopatologicznych. Dane te były całkowicie odizolowane i nie brały udziału w procesie uczenia, ani w przeszukiwaniu przestrzeni hiperparametrów przez algorytm Optuna.

W celu dostosowania systemu do asymetrycznych realiów diagnostyki medycznej – gdzie koszt przeoczenia patologii jest o wiele wyższy niż koszt fałszywego alarmu – badanie podzielono na dwa etapy:

- **Analiza wariantu bazowego** – Oparta na standardowej funkcji *Argmax* (sztywny próg prawdopodobieństwa) i klasyfikacja na podstawie najwyższego prawdopodobieństwa.
- **Analiza wariantu zoptymalizowanego medycznie** – Wykorzystująca indeks Youdena (J) do dynamicznego przesunięcia punktów odcięcia indywidualnie dla każdej klasy tkankowej.

Wzór na indeks Youdena:


$J = \text{Czułość} + \text{Specyficzność} - 1$, gdzie

Czułość = $TP / (TP + FN)$

Specyficzność = $TN / (TN + FP)$


WARIANT BAZOWY

W bazowej konfiguracji model uzyskał wskaźnik celności w testowym zbiorze na poziomie **94,33%**.




Wnioski na podstawie macierzy pomyłek dla wariantu bazowego:

- **Perfekcyjna separacja Klasy 1** – Model uzyskał w tej klasie idealny wskaźnik zbieżności i bezbłądność, co oznacza całkowite wyeliminowanie pomyłek dla tego typu tkanki.
- **Wysoka stabilność dla większości klas** – Klasy 0, 2, 3, 4, 6 i 8 uzyskały wysoki poziom dopasowania wynoszący ponad 94%.
- **Morfologiczne nieliniowe pomyłki** – Największą trudność dla sieci sprawiło rozróżnienie klasy 5 i 7. Model błędnie sklasyfikował aż 15% rzeczywistych przypadków Klasy 7 jako Klasę 5, co w kontekście klinicznym stwarza niebezpieczeństwo niedoszacowania realnej patologii.



Wnioski na podstawie analizy profilu metryk dla wariantu bazowego:

- **Asymetria metryk Klasy 1** – Czułość (Recall) na poziomie 100% kontrastuje z Precyzją (Precision) wynoszącą około 96%, co wskazuje, że model bezbłądnie wykrywa tę tkankę, generując przy tym marginalną liczbę fałszywych alarmów.
- **Niedoszacowanie klasy 7** – Klasa 7 została zidentyfikowana jako najslabsze ogniwo systemu, osiągając najniższy wskaźnik czułości na poziomie 74,11%. Oznacza to, że model przy standardowym progu pomija blisko 26% pacjentów z tą patologią – stanowi to bezpośrednie uzasadnienie dla kalibracji progów.




Wnioski na podstawie analizy krzywych ROC/AUC dla wariantu bazowego:

- **Znakomita separacja probabilistyczna** – Wszystkie klasy gwałtownie oddalają się od przerywanej linii klasyfikatora losowego (50% szans na wskazanie danej klasy lub dowolnej innej). Dodatkowo kilka z nich osiąga znakomity rezultat AUC na poziomie około 0,999.
- **Ukryty potencjał trudnych klas** – Nawet dla najtrudniejszej morfologicznie Klasy 7 model uzyskał wysokie AUC = 0.9688. Potwierdza to, że sieć posiada kompletną wiedzę strukturalną o tej patologii, a niski wskaźnik *Recall* (74,11%) wynika wyłącznie ze złego ustawienia punktu odcięcia, a nie z wadliwości samego modelu.


WARIANT ZOPTYMALIZOWANY

Wdrożenie procedury *Threshold Post-Processing* pozwoliło automatycznie wyznaczyć indywidualne, medyczne progi odcięcia prawdopodobieństwa. W efekcie globalny wskaźnik celności *Accuracy* wzrósł do poziomu **94,76%** na zbiorze testowym.



Wnioski na podstawie macierzy pomyłek dla wariantu zoptymalizowanego:

- **Wzrost wykrywalności Klasy 7** – Poprawna klasyfikacja dla tej klasy wzrosła z 0,74 na 0,79, co świadczy o podniesieniu bezpieczeństwa diagnostycznego pacjentów.
- **Stabilizacja Klasy 5** – Skuteczność rozpoznania tkanki dla Klasy 5 wzrosła z 0,86 do 0,91. Co szczególnie ważne – jest to klasa oznaczająca raka, a więc szczególnie istotna.
- **Zachowanie stabilności** – Pomimo zmiany progów, model utrzymał wskaźniki dla pozostałych klas, a dla Klasy 6 nawet poziom wzrósł z 0,96 na 0,97.



Wnioski na podstawie analizy metryk dla wariantu zoptymalizowanego:

- **Poprawa czułości** – Wzrost czułości dla Klas 5 i 7, z którymi był problem w poprzedniej wersji.
- **Kontrolowany spadek precyzji** – Kosztem poprawy czułości lekko spadła precyzja dla Klasy 7 z poziomu 85,01% do 84,09%, co jednak jest kosztem całkowicie pomijalnym w zamian za większe wykrywanie choroby.
- **Wzrost stabilności** – Słupki metryk na wykresie uległy widocznemu wyrównaniu, wzrost globalnej czułości średniej systemu wzrósł z 92,70% do 93,53%.

PODSUMOWANIE

Przeprowadzona faza zaawansowanej ewaluacji i post-processingu pozwala na sformułowanie następujących wniosków końcowych:

- **Sukces optymalizacji bayesowskiej** - Połączenie Transfer Learningu architektury *MobileNetV3* z optymalizacją bayesowską pozwoliło stworzyć model o potężnej sile dyskryminacyjnej, czego dowodem są wskaźniki *AUC* przekraczające 0,96 dla wszystkich klas histopatologicznych.
- **Konieczność kalibracji medycznej** - Eksperyment udowodnił, że standardowy algorytm *Argmax* jest niewystarczający w systemach klasyfikacji medycznej, ponieważ faworyzuje ogólną celność kosztem niebezpiecznego pomijania trudnych i rzadkich patologii.
- **Bezkosztowny zysk diagnostyczny** - Wykorzystanie indeksu Youdena do kalibracji progów pokazało, że zachowaniem sieci można efektywnie sterować na poziomie oprogramowania. Bez konieczności ponownego, wielogodzinnego uczenia sieci na GPU, zmieniono profil modelu na asymetryczny – nadwrażliwy na obecność tkanki patologicznej.

Ostatecznie, system osiągający 94,76% ogólnej celności przy jednoczesnym zabezpieczeniu krytycznych klas przed błędami fałszywie negatywnymi z powodzeniem spełnia rygorystyczne wymagania stawiane systemom wspomagania decyzji lekarskich w nowoczesnej patomorfologii cyfrowej.

Ostateczna wersja systemu opiera się na zamrożonej architekturze *MobileNetV3* połączonej z zewnętrznym modułem konfiguracyjnym w formacie JSON. Model nie wymaga ponownego trenowania ani modyfikacji strukturalnej – w procesie predykcji surowe prawdopodobieństwa zwracane przez sieć są automatycznie skalowane przez indywidualne, medyczne progi odcięcia

wyznaczone indeksem Youdena. Tak zaprojektowany potok post-processingu zostanie bezpośrednio zaimplementowany w docelowej aplikacji z graficznym interfejsem użytkownika (GUI) oraz w module interpretowalności (Grad-CAM), gwarantując asymetryczny, bezpieczny klinicznie werdykt diagnostyczny.

5. Interpretacja wyników i wyjaśnialność

SHAP, Grad-CAM i analiza błędów:

W tradycyjnych modelach uczenia maszynowego (np. lasy losowe, XGBoost), które operują na danych tabelarycznych, stopień istotności zmiennych wejściowych wyznacza się poprzez klasyczny wskaźnik *Feature Importance*. W przypadku głębokiej analizy obrazów histopatologicznych podejście to, podobnie jak algorytmy typu LIME, okazuje się niewystarczające. Pojedynczy piksel o współrzędnych (x, y) nie niesie ze sobą żadnej samodzielnej wartości diagnostycznej. Cechami kluczowymi dla modelu są wielowymiarowe struktury przestrzenne, gęstość komórkowa oraz tekstura tkankowa.

Aby przełamać barierę „czarnej skrzynki” (*Black-Box*) i zweryfikować, które cechy morfologiczne były najważniejsze dla zoptymalizowanej sieci *MobileNetV3*, wdrożono zaawansowane metody Wyjaśnialnej Sztucznej Inteligencji (XAI):

- **Grad-CAM** – Wykorzystujący przepływ gradientów do ostatniej warstwy splotowej w celu wygenerowania wizualnej mapy aktywności.
- **SHAP** – Oparty na teorii gier, badający matematyczny wpływ poszczególnych segmentów obrazu na ostateczną wartość prawdopodobieństwa wyjściowego.

Analizę przeprowadzono na bazie trzech unikalnych studiów przypadków (*Case Studies*):

- **Przypadek poprawnej klasyfikacji** (Poprawne wskazanie klasy w jednej z trudniejszych klas do klasyfikacji)
- **Przypadek granicznej klasyfikacji** (Poprawne wskazanie klasy w jednej z trudniejszych klas do klasyfikacji, dopiero po optymalizacji Youdena)
- **Przypadek błędnej klasyfikacji** (Błędne wskazanie klasy w jednej z trudniejszych klas do klasyfikacji)

PRZYPADK POPRAWNEJ KLASYFIKACJI




Wnioski:

- **Selektywność przestrzenna Grad-CAM** – Mapa aktywacji splotowych jednoznacznie wskazuje, że sieć *MobileNetV3* podjęła poprawną decyzję na podstawie analizy fragmentu

obrazka (prawego dolnego rogu oznaczonego kolorem czerwonym). Pokrywa się to bezpośrednio z gęstszym, skośnym układem struktur komórkowych widocznych na preparacie oryginalnym.

- **Polaryzacja uwagi sieci** – Model wykazał pożądaną separację tła od obiektów badanych. Obszary w lewym górnym rogu zostały zakwalifikowane jako neutralne (kolor niebieski), co udowadnia, że filtry splotowe prawidłowo zignorowały szum informacyjny.
- **Globalna stabilność i redundancja cech** - Wykres SHAP przyjął jednolitą, neutralną strukturę o ekstremalnie niskich wartościach matematycznych. Z uwagi na wysoką pewność modelu (95%), wybiórcze wygaszanie czy maskowanie pojedynczych superpikseli przez algorytm perturbacyjny nie było w stanie zachwiać predykcją sieci. Dowodzi to, że model *MobileNetV3* wyabstrahował globalny, rozproszony wzorec tekstury z całej powierzchni tkanki, a jego decyzja jest stabilna i odporna na lokalne anomalie czy pojedyncze piksele.


PRZYPADEK GRANICZNEJ KLASYFIKACJI



Wnioski:

- **Detekcja mikrostruktur Grad-CAM** – Mapa aktywacji splotowych jednoznacznie wskazuje, że sieć *MobileNetV3* podjęła poprawną decyzję na podstawie analizy fragmentu obrazka (prawego górnego rogu oznaczonego kolorem czerwonym). Model precyzyjnie wyizolował małe, skomasowane skupisko ciemniejszych struktur komórkowych, ignorując rozproszone, atypowe tło w lewej części obrazu.
- **Przewaga kalibracji progów Youdena** – Surowe prawdopodobieństwo wyjściowe sieci dla rzeczywistej Klasy 5 wynosiło zaledwie 1,17%. W klasycznym potoku decyzyjnym, próbka ta została bezpowrotnie odrzucona dla danej klasy, generując błędną klasyfikację. Wdrożenie zewnętrznej konfiguracji JSON z indeksami Youdena pozwoliło systemowi wychwycić ten subtelny sygnał i podjąć trafną decyzję diagnostyczną.
- **Analiza czułości lokalnej SHAP** - Wykres SHAP Local Plot utrzymał neutralną strukturę o wartościach bliskich zeru, co w tym przypadku wynika z operowania modelu w dolnym, silnie nieliniowym zakresie funkcji aktywacji. Model zakwalifikował próbkę jako pozytywną wyłącznie dzięki globalnemu przesunięciu progu decyzyjnego w post-processingu, a nie gwałtownej zmianie odpowiedzi na pojedyncze superpiksele, co potwierdza matematyczną stabilność algorytmu Youdena w warunkach wysokiej niepewności sieci.

PRZYPADEK BŁĘDNEJ KLASYFIKACJI



Wnioski:

- **Morfologiczne podobieństwo struktur** – Analiza wizualna próbki oryginalnej ujawnia podłużny, gęsty, skośny i bardzo zwarty układ włókien tkankowych. Jest to duże podobieństwo wizualne pomiędzy faktyczną Klasą 7, a przypisaną Klasą 5. Jest to bezpośrednia przyczyna pomyłki – nakładanie się cech wizualnych różnych klas w przestrzeni barw H&E, które zmyliło filtry sieci.
- **Globalne nasycenie sieci na mapie Grad-CAM** – Mapa aktywacji splotowych dla błędnej predykcji ukazała intensywną, niemal równomierną aktywację na całej powierzchni obrazka. Dowodzi to, że model nie sugerował się pojedynczym szumem, lecz dokonał błędnej generalizacji globalnego wzorca obecnego w całym kadrze.
- **Zjawisko nadmiernej pewności** - Model przypisał błędną klasę z pewnością aż 99,99%. Tak ekstremalnie wysoka pewność sieci sprawia, że funkcja *Softmax* na wyjściu jest całkowicie nasycona. Błąd nie wynika z niestabilności numerycznej sieci, lecz z zakwalifikowania całej tekstury obrazu do błędnej klasy przestrzennej. Podkreśla to konieczność traktowania modeli komputerowych jako narzędzi wspomagających, a nie zastępujących ostateczną decyzję lekarza.

6. Implementacja

Pobranie próbek do testów:




W celu przeprowadzenia wszechstronnych testów funkcjonalnych oraz demonstracji działania aplikacji desktopowej w czasie rzeczywistym, opracowano dedykowany skrypt pomocniczy *src/samples.py*, który za zadanie ma pozyskiwać zestaw danych w postaci próbki z każdej klasy z zestawu danych walidacyjnych.

Skrypt pobiera losowe próbki każdej klasy i zapisuje je w docelowym pliku. Nazwa pliku ma strukturę *Klasa_Czas.png*, co daje informacje o rzeczywistej klasie próbki, która potem wyświetlana jest w


aplikacji GUI, a także zapobiega nadpisywaniu plików w postaci różnego czasu wygenerowania danych.

Interfejs użytkownika:


W ramach projektu zaprojektowano i zaimplementowano dedykowany interfejs graficzny (GUI) przy użyciu biblioteki *PyQt6*. Aplikacja spełnia rolę systemu wspomagania decyzji medycznych. Interfejs został zoptymalizowany pod kątem pracy patomorfologa: uruchamia się automatycznie w trybie pełnoekranowym i spełnia potrzebne dla niego funkcje, z włączeniem wyjaśnialności decyzji klasyfikacji w postaci interaktywnego dostępu do mapy ciepła Grad-CAM.



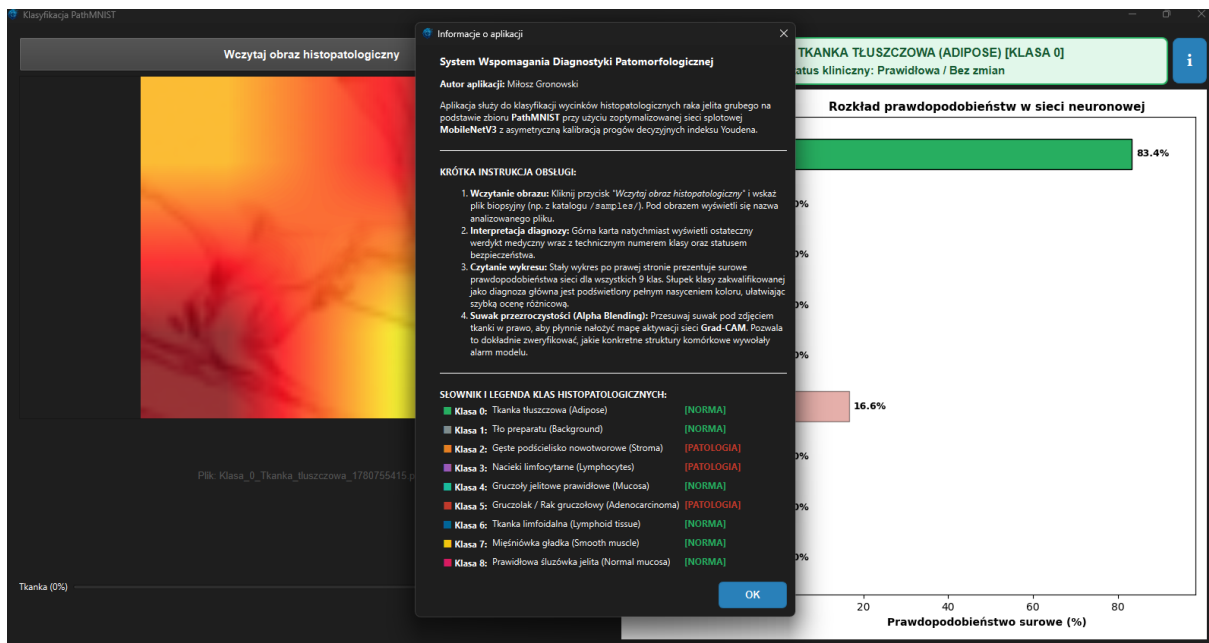
Po uruchomieniu aplikacji użytkownik widzi minimalistyczny panel podzielony dynamicznym separatorem (*QSplitter*). Lewa strona zawiera przestrzeń na plik graficzny oraz przycisk pozwalający na wczytanie pliku obrazowego. Prawy panel pozostaje nieaktywny, aż do zaczytania obrazu. W prawym górnym rogu znajduje się ikona informacji z dostępnym oknem modalnym. Widoczne jest autorskie logo aplikacji w lewym górnym rogu oraz na pasku zadań.



Po wciśnięciu przycisku do wczytywania obrazu, aplikacja automatycznie prowadzi do folderu `./samples`, ale można także wskazać inną ścieżkę do pliku. Po zaczytaniu obrazu, wyświetla się on na lewym panelu razem z nazwą pliku, podczas gdy na prawym panelu pojawia się informacja o diagnozie, statusie klinicznym oraz wykres słupkowy dotyczący rozkładu surowego prawdopodobieństwa na wskazane klasy z wyróżnieniem klasyfikacji modelu.




Aplikacja posiada w lewym dole ekranu suwak pozwalający na nałożenie maski Grad-CAM, w celu wyjaśnialności modelu na bieżąco. Można ustawić przezroczystość tej maski od 0-100% aby dowolnie wyświetlać ją na obrazie.

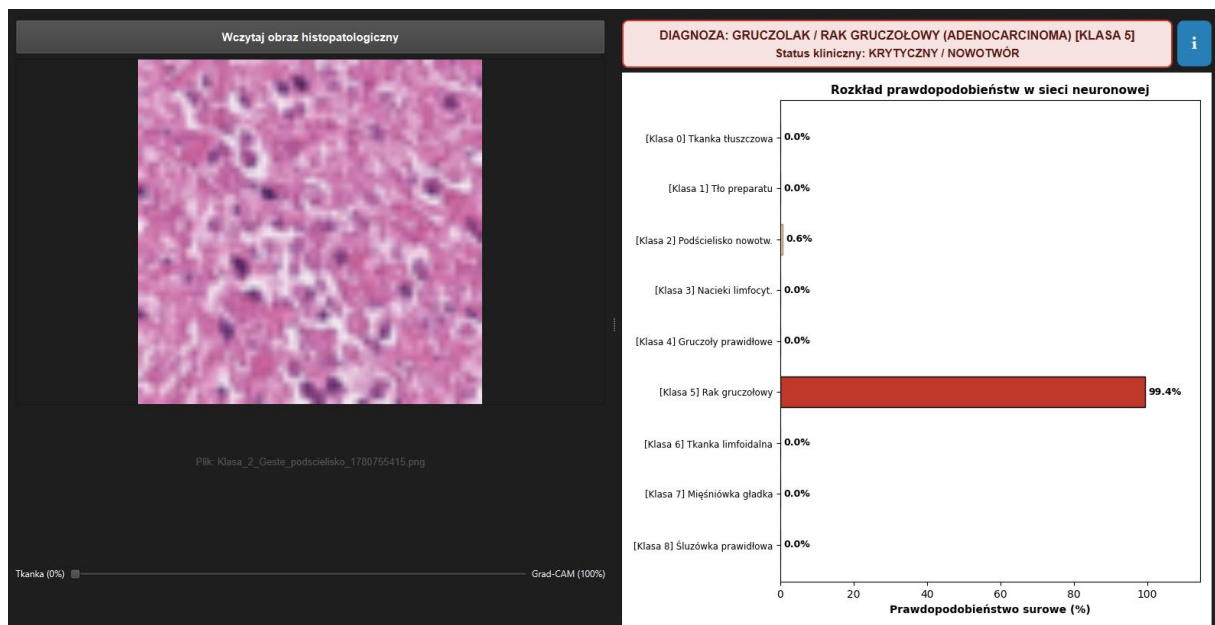


Zaimplementowano wyskakujące modalne okno po naciśnięciu przycisku z ikonką informacji. Okno posiada podstawowe informacje o aplikacji, krótką instrukcję obsługi. Rozpisane są tu także klasy i ich statusy kliniczne dla lepszego zapoznania się z klasyfikacjami modelu.


Przykładowe uruchomienia klasyfikatora:



Przykład poprawnej klasyfikacji modelu dla Klasy 5.



Przykład błędnej klasyfikacji modelu (Klasa 5 zamiast 2) – przykład diagnozy medycznej, w której klasyfikacja wskazuje negatywny wynik zdrowej diagnozy, pomimo rzeczywistej pozytywnej.



Przykład poprawnej klasyfikacji, w której inna klasa miała nieminimalną ilość % prawdopodobieństwa.

7. Instrukcja uruchomienia projektu

Instrukcja przygotowania danych, selekcji i uczenia modeli oraz optymalizacji, trenowania i ewaluacji ostatecznego modelu:

POBRANIE ZBIORU DANYCH

Przed rozpoczęciem procedury należy zaimportować surowy zbiór danych (dla projektu przyjęto obrazy o wielkości 64x64 piksele) w formacie skompresowanym *NumPy*, który powinien znajdować się w lokalizacji: */data/pathmnist_64.npz*.

Zbiór dostępny pod adresem: <https://zenodo.org/records/10519652>.

FAZA PRE-PROCESSINGU, INICJALIZACJA I ANALIZA EKSPLORACYJNA (EDA)

Pierwszym etapem potoku jest wczytanie medycznego zbioru danych w skompresowanym formacie *NumPy* oraz implementację dedykowanej klasy datasetu dla biblioteki *PyTorch*. Program automatycznie weryfikuje integralność danych, wyświetla raport balansu klas dla trzech podzbiorów (treningowy, walidacyjny, testowy) oraz dokonuje normalizacji matematycznej obrazów:

```
python -m src.data_loader
```

Następnym etapem jest weryfikacja integralności macierzy pikseli, walidacja balansu klas oraz wygenerowanie statystyk dystrybucji jasności i separowalności cech metodą rzutowania PCA:

```
python -m src.eda
```

Skrypt weryfikuje brak uszkodzeń danych w pliku *data_loader* oraz zapisuje wykresy analitycznych przestrzeni cech w katalogu */results/eda/*.

TRENOWANIE WSTĘPNE I SELEKCJA MODELU, SCREENING

W celu wyznaczenia optymalnej architektury bazowej, przeprowadzany jest test porównawczy 6 różnych modeli:

```
python -m src.models_train
```

```
python -m src.models_evaluate
```

Pierwszy z programów przeprowadza trening modeli na domyślnych parametrach i zapisuje historię uczenia do plików JSON w */results/models/*. Druga komenda agreguje te dane i generuje wykresy na ich podstawie w katalogu */results/model_charts/*, co pozwala porównać modele oraz wyselekcjonować optymalny model – w naszym przypadku *MobileNetV3*.

OPTIMALIZACJA HIPERPARAMETRÓW (OPTUNA)

Przed przystąpieniem do trenowania produkcyjnego, przestrzeń hiperparametrów sieci docelowej jest przeszukiwana bayesowsko z wykorzystaniem mechanizmu automatycznego odrzucania słabych prób (*pruning*):

```
python -m src.final_tune
```

Po 10 próbach optymalizacji hiperparametrów, do folderu */results/models/hyperparameters/* jest zwracana konfiguracja ich w postaci pliku *.json*.

FINALNY TRENING MODELU

Wyznaczone parametry są ładowane wraz z bazowym modelem do ostatecznego procesu uczenia sieci z aktywnym systemem wczesnego zatrzymywania (*Early Stopping*):

```
python -m src.final_train
```

Wynikiem treningu jest wytrenowany model zwrócony w katalogu */models/final_model/*.

EWALUACJA KOŃCOWA I KALIBRACJA MEDYCZNA

Przeprowadzenie testu na zbiorze testowym, generowanie krzywych oraz wyznaczanie progów Youdena optymalizujących czułość diagnostyczną klasyfikatora:

```
python -m src.final_evaluate
```

Wynikiem wykonania skryptu jest zapisanie macierzy pomyłek i profili metryk w */results/final_model/*, a także eksport matematycznych progów odcięcia prawdopodobieństwa do kluczowego pliku konfiguracyjnego w lokalizacji */models/final_model/*.

WYJAŚNIALNOŚĆ

Ostatnim krokiem potoku badawczego jest uruchomienie silników interpretowalności sztucznej inteligencji pod kątem weryfikacji map aktywacji oraz lokalnego wpływu cech na decyzje sieci:

```
python -m src.final_explain
```

Wynikiem wykonania skryptu jest ekstrakcja trzech studiów przypadku i wygenerowanie zbiorczych, potrójnych paneli graficznych (Oryginalna grafika + Grad-CAM + SHAP) w katalogu */results/final_model/explain/*.

Instrukcja uruchomienia aplikacji:

WYMAGANIA ŚRODOWISKOWE

W celu uruchomienia aplikacji niezbędna jest instalacja interpretera dla Pythona w wersji 3.12 oraz zainstalowanie zależności systemowych:

```
python -m pip install -r requirements.txt
```

WYMAGANE PLIKI

Dla uruchomienia aplikacji wymagane będą 2 pliki w folderze */models/final_model/*, dostępne także do pobrania, w celu pominięcia całego potoku treningowego i natychmiastowego uruchomienia interfejsu:

- Plik wag sieci ***mobilenetv3_final_optimized.pth***
Link do pobrania:
<https://github.com/Milosz180/pathMNIST-classification/releases/tag/Medical-Thresholds>
- Plik progów medycznych ***medical_thresholds.json***
Link do pobrania:
<https://github.com/Milosz180/pathMNIST-classification/releases/tag/network-weights>

METODA URUCHOMIENIA APLIKACJI 1

Podstawową metodą, która pomija konieczność znajomości ścieżek, plików i znajomości konsoli jest metoda uruchomienia pliku ***run_app.bat*** poprzez podwójne naciśnięcie na niego w folderze projektowym */pathMNIST/*. Skrypt automatycznie uruchomi aplikację za pomocą komendy, a interfejs uruchomi się samoistnie.

METODA URUCHOMIENIA APLIKACJI 2

Drugą metodą jest bezpośrednie uruchomienie skryptu z aplikacją z poziomu konsoli. Znajdując się w konsoli w głównym folderze projektu */pathMNIST/* należy uruchomić aplikację przez moduł:

```
python -m src.app
```

8. Podsumowanie

Wnioski:

W ramach projektu z powodzeniem zaprojektowano, zoptymalizowano i wdrożono kompletny system wspomagania decyzji medycznych (CADx), dedykowany klasyfikacji histopatologicznej raka jelita grubego na podstawie cyfrowych próbek biopsyjnych zbioru **PathMNIST**.

Główne osiągnięcia projektu:

- **Selekcja i optymalizacja architektury** – Po przeprowadzeniu systematycznego benchmarku 6 różnych modeli, wyłoniono sieć **MobileNetV3**, którą poddano bayesowskiemu dostrajaniu hiperparametrów za pomocą biblioteki *Optuna*. Pozwoliło to na zoptymalizowanie hiperparametrów i przeprowadzenie trenowania z dużym sukcesem.
- **Kalibracja medyczna** – Poprzez rezygnację ze standardowego wariantu decyzyjnego, który opierał się na największym prawdopodobieństwie dla danej klasy, postawiono na wykorzystanie statystyki **J Youdena**. Mechanizm minimalizował błędy typu False Negative w krytycznych klasach.
- **Interpretowalność** – wprowadzenie interpretowalności (np. poprzez **Grad-CAM**) pozwoliło na transparentne pokazanie przyczyn diagnozy.
- **Spełnienie roli w medycynie** – Aplikacja nie ma na celu zastąpienie lekarza, ale pełni rolę **niezależnego, cyfrowego asystenta** wspomagającego decyzję.

Problemy i ograniczenia:

Podczas realizacji projektu napotkano na pewne trudności i ograniczenia:

- **Konflikty kompilacji środowiskowej** – Próba stworzenia pliku .exe ujawniła problemy z relokacją bibliotek dynamicznych. Problem w aktualnej wersji projektu został rozwiązany poprzez przejście na natywne uruchomienie aplikacji z konsoli lub za pomocą pliku .bat.
- **Niestabilność lokalna metody SHAP** – Algorytm przeszukiwania przestrzeni cech metodą wartości Shapleya wykazywał duże zapotrzebowanie na moc obliczeniową, co uniemożliwiło wdrożenie techniki do GUI. Co ważniejsze z punktu widzenia interpretacji medycznej, lokalny profil SHAP okazał się bezużyteczny diagnostycznie, generując rozproszone, jednolite mapy wpływu o skrajnie niskim kontraście wizualnym.
- **Niska rozdzielczość wejściowa** – Wczytany zbiór PathMNIST, mimo swojej potężnej liczebności, operuje na silnie przeskalowanych wycinkach (64x64 pikseli). W realiach klinicznych lekarz patolog pracuje na wielogigabajtowych skanach całych slajdów biopsyjnych, gdzie kluczowy jest kontekst architektoniczny całej tkanki, a nie tylko pojedynczy, wyizolowany kadr. Była to jednak przykładowa rozdzielczość wybranego do projektu zbioru.
- **Szytywne progi klasyfikacji** – Klasyczny wybór diagnozy za pomocą *argmax*, traktował błędne klasyfikacje równorzędnie, co jest niedopuszczalne w medycynie. Problem rozwiązano za pomocą wdrożenia kalibracji opartej o statystykę **J Youdena**.

Możliwości rozwoju:

Pomysły na przyszłe rozszerzenia i ulepszenia projektu:

- **Implementacja innych rozdzielczości** – Przeprowadzenie analogicznych eksperymentów na innych rozdzielczościach zbioru PathMNIST i zbadaniem wpływu rozdzielczości na celność diagnostyczną.
- **Wielokrotna inicjalizacja wag** – Wdrożenie procedury uczenia modeli na kilku różnych, losowych ziarnach generatora i uśrednienie ostatecznych wyników predykcji, w celu zebrania większej liczby informacji na temat skuteczności modeli.
- **Powiększenie bazy testowanych architektur** – Powiększenie biblioteki modeli porównawczych w fazie wstępnej oraz wydłużenie ich wstępnego treningu lub zwiększenie liczby modeli w trenowaniu końcowym w celu optymalizacji większej bazy modeli.
- **Stworzenie pliku wykonawczego .exe** – Powrót do próby stworzenia aplikacji w formie pliku .exe do łatwiejszego wdrożenia systemu bez konieczności instalacji interpretera, środowiska czy znajomości instrukcji uruchomienia.
- **Integracja z platformą W&B** – Uzupełnienie potoku programistycznego o automatyczne logowanie metryk w chmurze w czasie rzeczywistym i porównywanie wykresów między różnymi uruchomieniami.

9. Link do repozytorium GitHub

Link do repozytorium:

<https://github.com/Milosz180/pathMNIST-classification>